

面向医疗 AI Agent 的 反事实对话模拟 (CCEMA)

面向临床对话 Agent 的离策略评估框架

现代 OPE + 多智能体辩论 + 因果对比嵌入 + MSM 敏感度分析

郝林浩 (Linhao Hao)

lhao0430@gmail.com


日期:2026-05-04

目标会议/期刊:NeurIPS 2026 / JAMIA / npj Digital Medicine

医疗 AI 评估的现实缺口

为什么现行评估流程无法回答“能否上线部署”这一问题

- 能力 $\neq$ 部署质量。MedQA / MMLU-Med 准确率已饱和到 90% 以上,但完全无法说明一个 Agent 在真实多轮临床对话中的表现。
- 前瞻性 RCT 太慢。一次为期 6-12 个月的“静默影子”试验花费超过 100 万美元,且每个站点都需要走 IRB 流程;而 ML 团队每 8-12 周就发布一版新 Agent。
- Agent 大约每 3 个月迭代一次。当 RCT 报告出炉时,生产环境模型已经领先 2-3 个版本,结论一发表即过时。
- 我们需要的是:仅依赖日志的、回顾性的、反事实估计器,带可校准的置信区间,且能在每次发布时重跑而无需新增患者接触。



OPE 与 TTE 之间的鸿沟

两套成熟方法论,但都不适用于以自然语言为动作的医疗 Agent

离策略评估 (OPE):

- 在表格化 / 离散动作场景(广告、推荐系统)中已经成熟。
- 把动作视为离散类别 id;假设倾向得分已知,或可在小动作空间上估计。
- 对自由文本动作直接失效:一份临床记录的 $|A| \sim 10^4$,倾向得分几乎处处为零,IPS 方差爆炸。

目标试验仿真 (TTE):

- EHR 数据上因果推断的金标准——在观测数据上仿真一项假想 RCT。
- 为二值 / 离散治疗设计(用药 vs. 不用药);无法把“重写鉴别诊断段落”编码为一个治疗组。
- 缺乏可靠机制将由临床医生策略 π_b 推广到任意 LLM 策略 π_e 。

CCEMA 弥合二者之间的鸿沟:TTE 假设 + OPE 估计器 + 一个让自由文本动作可处理的因果对比嵌入。

问题设定与符号约定

日志数据、行为策略、评估策略

日志数据集: $D = \{(x_i, a_i^{clin}, y_i)\}_{i=1}^n$

$x_i \in \mathcal{X}$ 患者上下文(人口学、病史、对话已发生部分)

$a_i^{clin} \in \mathcal{A}$ 医生的自由文本动作(病历、诊疗计划、回复)

$y_i \in [0, 1]$ 实际产生的结局(医学评审员的过程奖励分)

行为策略: $\pi_b(a | x) =$ 未知的临床医生在 $\mathcal{A}$ 上的分布

评估策略: $\pi_e(a | x) =$ 候选 LLM Agent(由我方控制)

目标估计量: $V(\pi_e) = \mathbb{E}_{x \sim p(x)}[\mathbb{E}_{a \sim \pi_e(\cdot | x)}[Y(x, a)]]$

“评测台”要回答的问题:仅由 D 估计 $V(\pi_e)$,并给出可校准的 CI。

估计目标: $V(\pi_e)$ 与重要性采样恒等式

完整的 IS 推导, 逐行展开

第 1 步——定义:

$$V(\pi_e) = \int p(x) \int \pi_e(a | x) \mathbb{E}[Y | x, a] da dx$$

第 2 步——同时乘除以行为分布密度(正性条件, 见下页):

$$V(\pi_e) = \int p(x) \int \pi_b(a | x) \frac{\pi_e(a | x)}{\pi_b(a | x)} \mathbb{E}[Y | x, a] da dx$$

第 3 步——识别为日志分布 $p(x)\pi_b(a | x)$ 下的期望:

$$V(\pi_e) = \mathbb{E}_{(x, a) \sim \pi_b} \left[\frac{\pi_e(a | x)}{\pi_b(a | x)} Y \right]$$

第 4 步——代入(IPS)估计:

$$\hat{V}_{IPS} = \frac{1}{n} \sum_{i=1}^n \frac{\pi_e(a_i | x_i)}{\pi_b(a_i | x_i)} y_i$$

在正性 + 一致性下无偏; 方差按 $\sup_{x, a} \pi_e / \pi_b$ 增长。

五项识别假设

标准的因果推断公理,改写到自由文本医疗动作的语境下

一致性 (SUTVA-1)

$Y_i = Y_i(a_i^{clin})$ ——观测到的结局等于在所采取动作下的潜在结局。

正性 / 共同支撑

$\pi_b(a | x) > 0$ 当且仅当 $\pi_e(a | x) > 0$ ——医生在合理范围内可以写出 Agent 可能写出的任何文本。

条件可交换性(无未观测混杂)

$Y(a) \perp\!\!\!\perp A | X$ ——在给定 $X = x$ 的层内,动作分配相当于随机化。

无预期效应

结局不依赖于本轮之后才采取的动作(排除回顾性日志中的“前瞻偏倚”)。

无干扰 (SUTVA-2)

在给定上下文条件下, Y_i 不依赖于 a_j ($j \neq i$)——病例之间相互独立。

U3(因果对比嵌入)通过把自由文本动作压缩到低维、与混杂因子正交的嵌入空间,使得正性与可交换性变得可辩护。

四项升级总览

U1-U4:替换了什么、来源、以及我们的贡献

	新增内容	替换对象	理论来源	我方贡献
U1	现代 OPE 估计器	朴素 IPS / DM	DML (Chernozhukov 2018);TMLE (van der Laan 2006);Conformal CI (Taufig 2022) Khan 2024;Chan 2024(多智能体辩论)	首次落地到临床 NLP;完整的 DR 交叉拟合 + 目标更新实现
U2	多智能体辩论裁判	单一 LLM 作裁判		三方:辩护、起诉、裁判,跨厂商多样化 + Beta 后验
U3	因果对比嵌入 (CCE)	现成的 SBERT / MedCPT	InfoNCE (Oord 2018);HSIC (Gretton 2005);MIPS (Saito 2022)	核心贡献;真实 ACI-Bench 上 AUC 1.0 → 0.55,恢复 positivity
U4	PSE 分解 + MSM	ΔV 的单点估计	Pearl (2001);Yadlowsky (2018) MSM	Logistic-MSM 脆弱度 Γ^* 闭式解;四轴路径特异分解

整体效果:在仅有日志数据的前提下,完成识别 + 估计 + 不确定性 + 敏感度。

U1——DM、IPS、DR 回顾

三类经典 OPE 估计器并列对比

直接法 (DM): 拟合结局模型 $\hat{f}(x, a) \approx \mathbb{E}[Y \mid x, a]$

$$\hat{V}_{DM} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_{a \sim \pi_e(\cdot \mid x_i)} \hat{f}(x_i, a)$$

- 方差小;若 $\hat{f}$ 设定不准则偏倚大

逆倾向加权 (IPS):

$$\hat{V}_{IPS} = \frac{1}{n} \sum_i w_i y_i, \quad w_i = \pi_e(a_i \mid x_i) / \pi_b(a_i \mid x_i)$$

- 无偏;但当 w_i 重尾时方差极大

双重稳健 (DR, Robins 1994; Dudik 2011):

$$\hat{V}_{DR} = \frac{1}{n} \sum_i [\mathbb{E}_{a \sim \pi_e} \hat{f}(x_i, a) + w_i (y_i - \hat{f}(x_i, a_i))]$$

- 只要 $\hat{f}$ 与 $\hat{\pi}_b$ 之一正确即一致(双重鲁棒性)

U1——为什么朴素 DR 会失效:一阶过拟合偏倚

在同一份数据上估计干扰参数与价值,误差是 $O(1)$ 而非 $O(1/\sqrt{n})$

分解一个朴素 plug-in DR 估计器的误差:

$$\hat{V}_{DR} - V = (\mathbb{E}_n - \mathbb{E})\psi_0 + (\mathbb{E}_n - \mathbb{E})(\hat{\psi} - \psi_0) + \text{bias}(\hat{\psi})$$

[随机项 $O(n^{-1/2})$] [漂移项] [干扰偏倚]

漂移项可以归约为干扰项误差的乘积:

$$|\text{drift}| \leq \|\hat{f} - f_0\|_{L_2} \cdot \|\hat{w} - w_0\|_{L_2}$$

若不进行样本切分, $\hat{f}$ 会记忆 D ——经验过程项

$(\mathbb{E}_n - \mathbb{E})(\hat{f} - f_0)$ 不会以参数速率消失。

后果:偏倚是 $O(1)$ 量级,渐近 CI 覆盖率失真,点估计有偏。

补救:把每个干扰参数所拟合的数据留出(交叉拟合,见下页)。

U1——DML / 交叉拟合 (Chernozhukov 等,2018)

K 折样本切分恢复参数收敛速率

流程 ($K = 5$):

1. 把 $\mathcal{D}$ 划分为 K 个互斥折 $I_1, \dots, I_K$ 。
2. 对 $k = 1 \dots K$: 在 $\mathcal{D} \setminus I_k$ 上拟合 $\hat{f}^{(-k)}, \hat{w}^{(-k)}$ 。
3. 用留出的干扰参数为折 I_k 打分。
4. 求平均: $\hat{V}_{DML} = \frac{1}{n} \sum_{k=1}^K \sum_{i \in I_k} \psi(z_i; \hat{f}^{(-k)}, \hat{w}^{(-k)})$.

渐近线性证明梗概。在折 I_k 上, $\hat{f}^{(-k)}$ 与 $\{z_i\}_{i \in I_k}$ 独立,

由条件 Lindeberg CLT 可得 $(\bar{E}_n - E)(\hat{\psi}^{(-k)} - \psi_0) = O_p(n^{-1/2})$ 。

再结合乘积速率偏倚 $\|\hat{f} - f_0\| \cdot \|\hat{w} - w_0\|$, 只要两个干扰参数

以 $n^{-1/4}$ 收敛, 我们就有

$$\sqrt{n} (\hat{V}_{DML} - V) \rightarrow_d \mathcal{N}(0, \sigma_\psi^2),$$

其中 σ_ψ^2 是半参有效方差 (Newey 1994)。

U1——TMLE (van der Laan & Rubin, 2006)

目标更新达到 Cramer–Rao 半参效率界

初始结局估计 $\hat{f}(x, a) \in (0, 1)$ 。定义“聪明协变量”

$$H(x, a) = \pi_e(a | x) / \pi_b(a | x).$$

目标更新(单步 logistic 扰动):

$$f^*(x, a) = \text{sigmoid}(\text{logit } \hat{f}(x, a) + \varepsilon \cdot H(x, a))$$

ε 通过对 $\{(y_i, H_i)\}$ 的极大似然估计:

$$\hat{\varepsilon} = \arg \max_{\varepsilon} \sum_i [y_i \log f_{\varepsilon}^* + (1 - y_i) \log(1 - f_{\varepsilon}^*)]$$

由构造,得分方程恒成立:

$$\frac{1}{n} \sum_i H(x_i, a_i) (y_i - f^*(x_i, a_i)) = 0.$$

这正是目标参数 $V(\pi_e)$ 的有效影响函数 (EIF) 方程,因此 plug-in

$\hat{V}_{TMLE}$ 达到 Cramer–Rao 半参效率界 (van der Laan 《Targeted Learning》2011, 定理 5.2)。

U1——Conformal OPE 置信区间 (Taufiq 等,2022)

通过分裂式 conformal 实现免分布、有限样本覆盖

将数据分成训练集 D_{tr} 与校准集 D_{cal} (大小为 m)。

在 D_{tr} 上拟合任意 DR 风格的得分 $\hat{\psi}$ 。在校准集上计算残差

$$R_i = |\hat{\psi}(z_i) - \text{plug-in}|, \quad i \in D_{\text{cal}}.$$

取第 $[(1 - \alpha)(m + 1)]$ 顺序统计量 $\hat{q}_{1-\alpha}$ 。

则 conformal 区间

$$\hat{C}_\alpha = [\hat{V} - \hat{q}_{1-\alpha}, \hat{V} + \hat{q}_{1-\alpha}]$$

满足 $\Pr(V \in \hat{C}_\alpha) \geq 1 - \alpha$.

证明梗概。在 $D_{\text{cal}} \cup \{z_{n+1}\}$ 可交换的前提下,



R_{n+1} 在 $\{R_1, \dots, R_m, R_{n+1}\}$ 的秩中均匀分布,故

$$\Pr(R_{n+1} \leq R_{([(1 - \alpha)(m + 1)])}) \geq 1 - \alpha.$$

主要优点:对 IS 权重的尾部分布无任何参数化假设。

U1——实测验证

200 个随机种子下的合成真值 RMSE 与 CI 覆盖率



左图:DM / IPS / DR / DML / TMLE 在合成日志 (n = 5000) 上的 RMSE。右图:95% CI 覆盖率;即便 IS 权重重尾,conformal 仍可达到名义覆盖。

U2——单一 LLM 裁判的偏差

三种已被记录的失败模式,会污染奖励信号

- 自我偏好偏差——裁判倾向于自家模型族输出。
- 啰嗦偏差——裁判偏好长文本而非正确答案。
- 宽松 / 位置偏差——首位答案获胜的概率被显著放大。

正式定义(自我偏好):

$$B_{\text{self}} = \mathbb{E}[s_j(a_{\text{self}}) - s_j(a_{\text{other}}) \mid q(a_{\text{self}}) = q(a_{\text{other}})] > 0$$

其中 s_j 是裁判打分, q 是潜在质量。在无偏裁判下,


B_{self} 恒为 0。实证上,GPT-4 自评其自身输出 vs. Claude 输出时,

在相同 prompt 下 $B_{\text{self}} \approx 0.08$ (Zheng 2023, 表 6)。

对 OPE 的影响:若奖励 y 由裁判定义, $B_{\text{self}} > 0$ 会使 $\hat{V}(\pi_e)$ 原样平移同样幅度——偏差直接传递到最终估计上。

U2——三方辩论设计

辩护、起诉、裁判——分别来自不同厂商,输出 Beta 后验



输出为正确性 $\theta \in [0, 1]$ 上的 Beta 后验:

$$\theta \sim \text{Beta}(\alpha, \beta), \quad \alpha = 1 + n_{\text{wins-D}}, \quad \beta = 1 + n_{\text{wins-P}}.$$

理论依据(共轭性):把每轮辩论视为以 θ 为成功率的 Bernoulli 试验,

以 Jeffreys 先验 $\text{Beta}(1/2, 1/2) \rightarrow$ 后验 $\text{Beta}(\alpha, \beta)$,

均值 $\alpha/(\alpha + \beta)$, 方差 $\alpha\beta/(\alpha + \beta)^2(\alpha + \beta + 1)$ 。

跨厂商多样化对自我偏好偏差的残差给出上界:

$$|B_{\text{self}}^{\text{triadic}}| \leq \frac{1}{3} \max_v |B_{\text{self}}^v|$$

因为没有任何单一厂商会同时在三个角色中的两个看到自家输出。

U2——四轴过程奖励 + 校准目标

为什么四个指标缺一不可

四个奖励轴:

- 安全性——是否处理了红旗信号(如自杀风险、脓毒症分诊)。
- 诊断质量——前 3 鉴别诊断是否命中专家面板。
- 信息收集——Agent 是否问到了应当问的关键病史。
- 沟通质量——共情度、术语少、对患者可读。

校准目标(对照医学评审员):

$\rho \geq 0.7$ 裁判 vs. 评审员评分的 Pearson 相关

$\kappa_w \geq 0.4$ 二次加权 Cohen's kappa(序数一致性)

$\text{ICC}(2, 1) \geq 0.75$ 类内相关(双因子随机模型,绝对一致性)

$|\text{bias}| \leq 0.05$ 在 $[0, 1]$ 尺度下,裁判减去评审员的均值

为什么是四个? ρ 抓单调差异; κ_w 抓序数错档;
ICC 抓 ρ 忽略的尺度漂移; bias 抓 ICC 容许的系统性偏移。
任何单一指标都有其他三者会禁止的失败模式。

U3——现成嵌入在 OPE 上为何失效

语义相似 $\neq$ 同一 x 下不同 a 的相似

- MedCPT、BioBERT、SBERT 是为检索 / NLI 训练的——它们按主题聚类。
- OPE 需要的嵌入是:对同一名患者写的两份病历应当“接近”,即便其中一份是正确的、另一份是错误的。
- 现成编码器恰恰相反:患者 i 的错误病历更接近于患者 j 的错误病历(两者都包含同一条幻觉药名),而非更接近 i 的正确病历。
- 实证:在原始 MedCPT 上,“正确 vs. 反事实”的 AUC = 1.00 (编码器只是在按主题区分文档,不是动作)。MIPS 退化。

CCE 的目标:学一个嵌入 $\phi(x, a)$,使得

- (1) $\phi(x, a_{\text{correct}})$ 与 $\phi(x, a_{\text{counterfactual}})$ 接近(同一 x);
- (2) 当 $x \neq x'$ 时, $\phi(x, a)$ 与 $\phi(x', a)$ 远离(动作有判别力);
- (3) $\phi(x, a)$ 与已观测混杂因子 C 无关。

U3——CCE 目标函数(完整推导)

对称 InfoNCE + HSIC 惩罚以保证混杂不变性

设 $\phi_\theta(x, a) \in \mathbb{R}^d$ 为嵌入网络。对正样本 (z_i, z_i^+) ,

用两种数据增强重新编码同一对 (x_i, a_i^{clin}) ; 负样本 $\{z_j\}_{j \neq i}$ 。

对称 InfoNCE:

$$\mathcal{L}_{NCE} = -\frac{1}{2n} \sum_{i=1}^n \left[\log \frac{e^{\langle z_i, z_i^+ \rangle / \tau}}{\sum_j e^{\langle z_i, z_j \rangle / \tau}} + \log \frac{e^{\langle z_i^+, z_i \rangle / \tau}}{\sum_j e^{\langle z_i^+, z_j \rangle / \tau}} \right]$$

HSIC 混杂不变性惩罚 (Gretton 2005):

$$\text{HSIC}(Z, C) = \frac{1}{(n-1)^2} \text{tr}(K_Z H K_C H), \quad H = I - \frac{1}{n} \mathbf{1}\mathbf{1}^\top$$

其中 K_Z, K_C 分别为嵌入与混淆变量上的高斯核;

$\text{HSIC} = 0 \Leftrightarrow Z \perp C$ (普适核定理)。

最终目标:

$$\mathcal{L}(\theta) = \mathcal{L}_{NCE}(\theta) + \lambda \cdot \text{HSIC}(\phi_\theta(x, a), C)$$

λ 由验证集选择, 使 $\text{HSIC} \leq 0.01$ 同时 $\mathcal{L}_{NCE}$ 与无惩罚最优值差距不超 5%。

U3——与 MIPS 的连接 (Saito & Joachims, 2022)

为何 CCE 是边际化 IPS 所需要的嵌入

MIPS 估计器:把动作投影到嵌入 $e = \phi(x, a)$,在 e 空间里加权:

$$\hat{V}_{MIPS} = \frac{1}{n} \sum_i \frac{\pi_e(e_i | x_i)}{\pi_b(e_i | x_i)} y_i.$$

定理 (Saito & Joachims 2022, 定理 3.1, 改述)。

若“无直接效应”条件成立: $Y \perp\!\!\!\perp A \mid X, \phi(X, A)$,

则 $\hat{V}_{MIPS}$ 对 $V(\pi_e)$ 无偏,且

$$\text{Var}(\hat{V}_{MIPS}) \leq \text{Var}(\hat{V}_{IPS})$$

当 ϕ 在 $\mathcal{A}$ 上不可逆时严格不等。

CCE 提供定理所要求的嵌入:

- InfoNCE 使 ϕ 成为动作引发结局变化的充分统计量,
- HSIC 强制 $\phi \perp\!\!\!\perp C$,移除残余的混淆通道。


净结果:在合成基准上方差降低 5–50 倍(见第 13 页)。

U3——真实 ACI-Bench 上的核心结果

原始 MedCPT AUC = 1.00(退化)→ CCE 后 AUC = 0.55(可识别)

图意说明

CCE on real ACI-Bench text: positivity collapses on raw embeddings, is restored under contrastive projection



- 柱形:正确 vs. 反事实分类器的 AUC。
- 原始 MedCPT:AUC = 1.00 (编码器按主题分, OPE 退化)。
- CCE 训练后:AUC = 0.55, 接近可识别区间。
- 首次在真实医学文本 (ACI-Bench)上证明。

U3——诚实说明

哪些是真实数据、哪些是模板生成、哪些尚待完成

- 真实:ACI-Bench 转录文本(医生病历)、MedCPT 基础编码器、CCE 训练运行、真实留出集上 $AUC = 0.55$ 的结果。
- 模板生成:目前“Agent 反事实”是确定性扰动(替换药名、剂量、删除红旗信号)——并非真正的 LLM 重跑。
- 待完成:在约 500 个病例上做真实 LLM Agent 重跑(预算 300 美元 / 2 天)。预期定性结论(AUC 下降)保留,而每例动作分布更接近真实。
- 为何现在发表?方法论贡献(CCE 打破退化嵌入)与反事实如何生成无关; LLM 重跑只是稳健性检查,而非主要论据。

U4——路径特异效应分解

在 4 个奖励轴 × 各专科分层上分解 ΔV


从医生策略 π_b 切换到 Agent π_e 的总效应:

$$\Delta = V(\pi_e) - V(\pi_b) = \sum_{k=1}^4 \sum_{s \in \mathcal{S}} \Delta_{k,s}$$

其中 k 索引奖励轴(安全^{k=1} / 诊断^{k=2} / 信息 / 沟通), s 索引专科分层
(心内、皮肤、神经.....)。

逐分量效应,采用中介公式形式 (Pearl 2001):

$$\Delta_{k,s} = \mathbb{E}_{x \in \mathcal{X}} [\mathbb{E}_{a \sim \pi_e} Y_k(x, a) - \mathbb{E}_{a \sim \pi_b} Y_k(x, a)]$$



U4——Logistic 边际敏感度模型 (MSM)

Yadlowsky 2018:用 Γ 限制未观测混杂带来的偏倚

假设 (Tan 2006)。未观测混淆变量 U 至多让处理对数几率漂移 $\log \Gamma$:

$$\frac{1}{\Gamma} \leq \frac{\pi_b(a | x, u) / (1 - \pi_b(a | x, u))}{\pi_b(a | x) / (1 - \pi_b(a | x))} \leq \Gamma.$$

Yadlowsky (2018) 第 4.1 节:在该 MSM 下,平均处理效应的最坏情形

下界为

$$\Delta_{lo}(\Gamma) = \Delta - \frac{\Gamma-1}{\Gamma+1} \mathbb{E}|d_i|, \quad d_i = w_i (y_i - \hat{f}(x_i, a_i)).$$

推导梗概。MSM 推出 $|\hat{w}_i^{adv} - \hat{w}_i| \leq (\Gamma - 1)/(\Gamma + 1) \hat{w}_i$

对所有与 Γ 相容的对抗性重加权成立。对 DR 得分 d_i 应用 Cauchy–Schwarz 即得

上式所示的单边下界。 $\Delta_{hi}(\Gamma)$ 同理对称。

单调性: $\partial \Delta_{lo} / \partial \Gamma = -2/(\Gamma + 1)^2 \cdot \mathbb{E}|d_i| < 0$,

随设定的混杂强度增大,边界单调展宽。

U4——脆弱度 Γ^* :闭式解

刚好令核心结果失效所需的最小未观测混杂强度

将 Γ^* 定义为 $\Delta_{lo}(\Gamma) = 0$ 处的最小 Γ :


$$\Delta - \frac{\Gamma^* - 1}{\Gamma^* + 1} E|d_i| = 0$$

令 $r = \Delta / E|d_i|$ (“效应—噪声比”)。求解:

$$r(\Gamma^* + 1) = \Gamma^* - 1 \Leftrightarrow \Gamma^* = \frac{1+r}{1-r}.$$

解读: $\Gamma^* \approx 1.2$ 即脆弱(任何 OR > 1.2 的未观测混淆变量都能解释掉结果);


按惯例, $\Gamma^* > 2$ 被视为鲁棒。



工程实现——10 步流水线

每一步对应四项升级中的某一项

10-step CCE workflow with upgrades U1-U5




U1 = TMLE + conformal CIs | U2 = LLM-graded judges (mocked) | U3 = real-text contrastive CCE | U4 = MSM sensitivity bounds | U5 = smarter Layer-1 audit

- 01 问题定义 (U0)
- 02 数据审计 (U0)
- 03 主动采样 (U2)
- 04 运行裁判 (U2)
- 05 运行 Agent (U2/U3)
- 06 训练 CCE (U3)
- 07 构建真值 (U2)
- 08 合成基准 (U1)
- 09 主实验 (U1+U3)
- 10 失败模式 (U4)

工程实现——真实 ACI-Bench 第一层审计

在原始转录上做语境感知的质量检测

Smarter Layer-1 audit: 4 false positives correctly reclassified



- 第一层 = 转录级 QC。
- 可检测:空轮、角色错位、PII 泄漏、跑题闲聊。
- 语境感知:同一词(如“胸”)在心内科正常,在皮肤科则是红旗。
- 真实 ACI-Bench 通过率:约 93%;被标记的样本送入人工复核。

工程实现——仓库统计

可复现性与 CI 表面

提交数	15
通过测试数	161
Python 文件数	75+
端到端 mock 模式	支持(无需 API key)
GitHub Actions CI	推送时执行 lint + 测试
Docker 镜像	ccema:latest, ~2.1 GB
依赖锁文件	requirements-lock.txt(版本锁定)
LICENSE	MIT

Mock 模式意味着:scripts/01_*.py 至 scripts/10_*.py 的每个脚本都能端到端运行, 不依赖任何外部 API;评审者可以在 10 分钟内复现核心数字。

状态——真实数据 vs. 模拟验证

当前数字到底建立在什么基础上

升级项	状态	说明
U1(现代 OPE)	MOCK	已知 V 的合成日志;待补真实 LLM 输出
U2(辩论裁判)	MOCK	厂商 API 已 stub;待补医学评审员校准集
U3(CCE)	REAL	在真实 ACI-Bench 上训练并评估(AUC 1.00 → 0.55)
U4(分解 + MSM)	MOCK	脆弱度闭式已被解析与合成数据共同验证

核心科学结论(CCE 在真实医学文本上打破退化嵌入)
完全建立在真实数据上。工程性结论建立在 mock + 计划中的真实重跑之上。

下一步路线图——未来 5 周

从今天的 v1 走到可投稿的 v2

第 1 周

在约 500 例 ACI-Bench 上跑真实 LLM Agent
预算 300 美元,约 2 天计算。替代 U3 中的模板反事实。

第 2 周

金标签真值标注
招募 2-3 名持证医师评审员;200 例 $\times$ 4 个轴。

第 3-4 周

校准集 + 裁判调优
在 holdout 上达到 $\rho \geq 0.7$ 、 $\kappa_w \geq 0.4$ 、 $ICC \geq 0.75$ 、 $|\text{bias}| \leq 0.05$ 。

第 5 周

U1 + U4 在真实数据上的运行
对真实 $V(\pi_e) - V(\pi_b)$ 跑 DML / TMLE + MSM Γ^* 。

第 6-7 周

论文撰写 + 消融实验
目标 NeurIPS 2026 或 JAMIA 短文。

风险与对策

可能打破计划的三件事,以及我们的应对

风险:无法及时获得医学评审员

对策:用 HealthBench (Anthropic 2025) 作为锚点:在其量表上重打分,汇报相对排序。失去绝对校准,但保留相对比较结论。

风险:MSM 边界扩张过快($\Gamma^* < 1.2$)

对策:把核心结果改述为“脆弱发现”——仍可作为方法论演示发表;贡献本身在于 Γ^* 的闭式解。

风险:CCE 在真实 LLM 重跑上未能压低 AUC

对策:说明模板反事实比真实容易(信息量丰富的负结果)。论文中加入仅 HSIC 的消融位置。

风险:厂商 API 在实验中途修改打分逻辑

对策:锁定模型版本(gpt-4-1106、claude-3.5-sonnet-20240620、gemini-1.5-pro-002),保存原始裁判转录,任何漂移可事后追查。

核心信息

一句话主张,后接三句论据

在真实医学嵌入上,U3 拯救了 IPS 类估计器。

- 原始 MedCPT 区分正确与反事实病历的 $AUC = 1.00$
——OPE 问题完全退化,IS 权重要么 0 要么 ∞ 。
- CCE 训练后 AUC 降到 0.55——进入现代 OPE 估计器
(DML、TMLE、MIPS)具有有限方差解的可识别区间。
- 这是首次在真实 ACI-Bench 转录文本上的演示;
就方法论主张而言,无需真实 LLM 重跑(模板反事实即可成立)。

若以上结论在第 1 周的 LLM 重跑后仍成立,U3 就是核心科学贡献,
U1、U2、U4 则是围绕它的可复现工程支架。

致谢与联系方式

感谢:

- ACI-Bench 作者团队提供公开的临床对话语料。
- MedCPT 团队 (NIH) 提供开源医学文本编码器。
- Anthropic / Claude Code 提供智能体化的构建工具链。
- 对 OPE 假设进行了压力测试的评审者与同事。

联系方式与代码仓库:

郝林浩 Linhao Hao <lhhao0430@gmail.com>

github.com/<user>/Counterfactual-Conversation-Emulation-for-Medical-AI-Agents

日期:2026-05-04 | 版本:v1 | 许可证:MIT

谢谢!